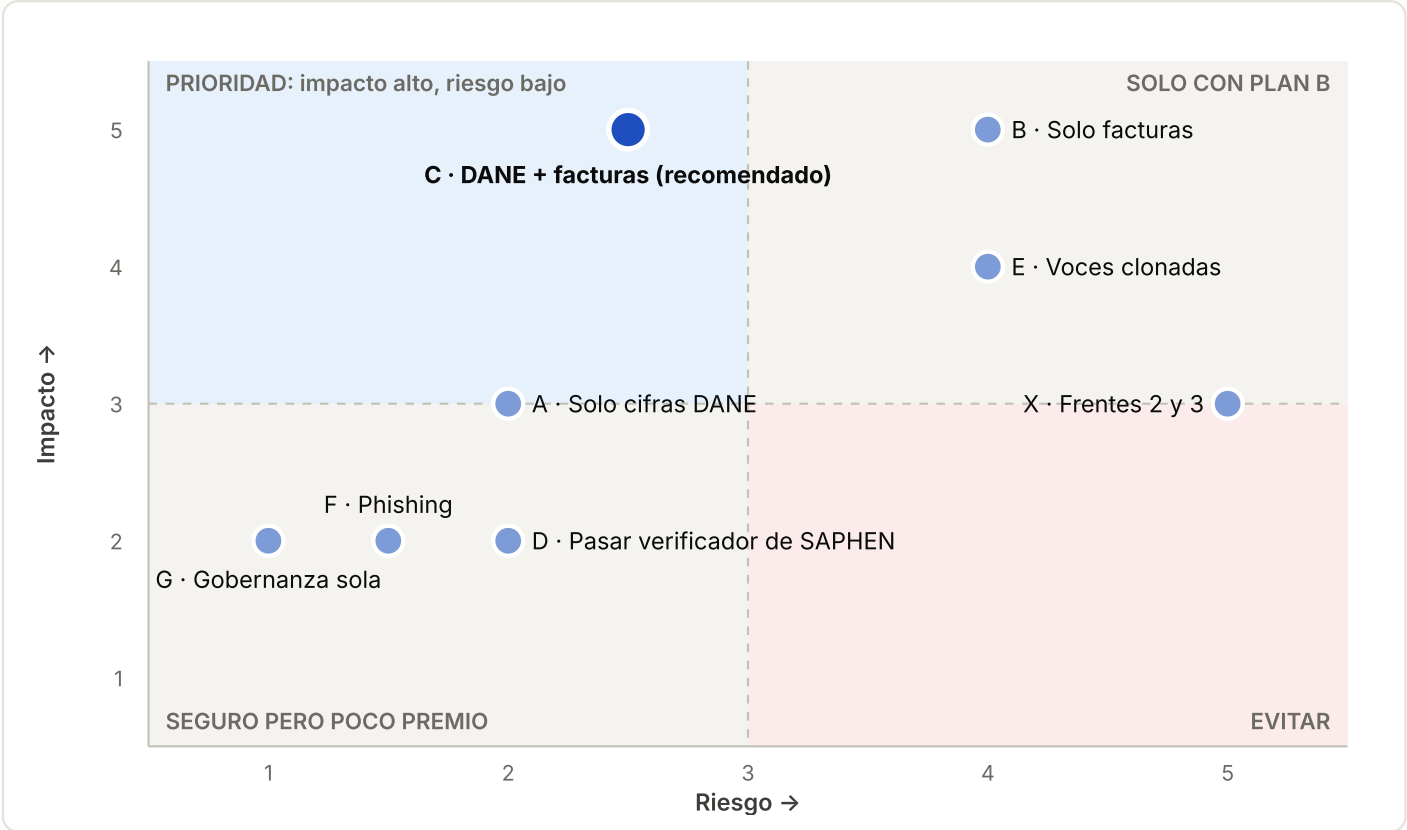
Matriz de riesgo e impacto

Defensive Acceleration Hackathon · Uniandes · sábado 14 de noviembre de 2026 · Actualizado el 8 de noviembre de 2026

> **Decisión recomendada (C):** un solo proyecto con dos escenarios y las mismas defensas. En la mañana construimos el escenario seguro, con las **cifras oficiales del DANE**. En la tarde, si a las 3:00 p.m. hay tiempo, agregamos el escenario de impacto: **facturas tipo SAPHEN**. Si las facturas no alcanzan, igual entregamos un proyecto completo con el DANE.

1. Todas las opciones en una matriz

Impacto es lo que la opción puede sumar en la rúbrica: relevancia (20 %), evidencia (25 %) y qué tanto se diferencia. Riesgo es la probabilidad de no tener nada funcionando a las 5:00 p.m. o de incumplir una regla. Los puntajes van de 1 a 5 y son una estimación nuestra.



2. Detalle de cada opción

Opción	Qué construimos	Impacto	Riesgo	Riesgo principal y cómo lo manejamos	Veredicto
C DANE + facturas, un proyecto con dos escenarios (frente 1)	Mañana: réplica del agente del DANE con consultas aprobadas, verificador de cifras y ataques ocultos en documentos. Tarde: 10 a 20 facturas sintéticas con instrucciones ocultas y una compuerta antes de aprobar.	5	2,5	Dispersarse. Hora de corte a las 3:00 p.m.: si las facturas no están, se entrega el DANE completo y las facturas como trabajo en curso.	**Recomendado**
A Solo cifras DANE (frente 1)	Lo de la mañana de C, más la comparación entre verificador que avisa y verificador que bloquea.	3	2	Impresiona menos porque no hay plata en juego. Se compensa con una medición muy clara.	**Base segura (es la mañana de C)**

Opción	Qué construimos	Impacto	Riesgo	Riesgo principal y cómo lo manejamos	Veredicto
B Solo facturas tipo SAPHEN (frente 1)	Generador de facturas sintéticas, extracción con Gemini, reglas fijas (subtotal + IVA = total, dígito de verificación del NIT, segunda extracción con OCR) y compuerta.	5	4	Todo se construye el mismo día, con imágenes y OCR. Si algo falla, no queda nada que entregar.	**Solo como tarde de C**
E Voces clonadas con HABLA (frente 4)	Detector AASIST-L ajustado con audios en español y comprimidos como en WhatsApp.	4	4	Necesita GPU, descargas de varios GB y que el profesor domine audio.	**Plan B solo si el profesor domina audio**
F Phishing con SpaPhish (frente 4)	Clasificador de correos que además explica qué técnica de persuasión usa.	2	1,5	Lo van a hacer varios equipos, así que se diferencia poco.	**Plan C si el profesor no puede ir**
D Pasar el verificador de SAPHEN a Python	Traducir de TypeScript las reglas de citas jurídicas.	2	2	Repite lo que ya hace el verificador de cifras.	**No. Solo tomar sus casos de prueba**
G Estándar de gobernanza solo (frente 5)	Requisitos para agentes con datos públicos o de salud, cada uno con su prueba.	2	1	Un documento compite contra prototipos que funcionan.	**Solo como anexo de C**
X Frentes 2 y 3	Monitores de sabotaje, verificación formal.	3	5	Son retos para especialistas en control de IA y en métodos formales.	**Descartados**

Extra opcional de C, de riesgo bajo: tu amigo escribe un anexo con el estándar de gobernanza, tomando las reglas del DANE y los controles de SAPHEN como caso real.

3. Riesgos que afectan a cualquier opción

Riesgo	Probabilidad	Impacto	Cómo lo manejamos	Responsable	Cuándo
El profesor no puede estar en Bogotá el sábado	🟡 Media	🔴 Muy alto	Confirmarlo hoy. Si no puede, equipo de dos con phishing (F).	Tú	Dom 8
Postulación tardía o incompleta	🟢 Baja	🔴 Muy alto	Los tres envían el formulario el lunes 9, no el martes en la noche, con el mismo texto.	Todos	Lun 9
No permiten llevar código hecho de antes	🟡 Media	🔴 Alto	Preguntar a la organización. Llevar solo el entorno instalado, los datos y las especificaciones, y declararlo en la ficha.	Tú	Mié 11
Falla la API del modelo o se acaban los créditos	🟡 Media	🔴 Alto	Claves de dos proveedores, guardar las respuestas para no repetir llamadas y fijar un límite de llamadas.	Profesor	Mié 11
Internet lento en el campus	🟡 Media	🔴 Alto	Datos y modelos guardados en los portátiles y un celular para compartir datos.	Todos	Vie 13
Las facturas no están listas a las 3:00 p.m.	🟡 Media-alta	🟡 Medio	Respetar la hora de corte: se entrega el DANE completo y las facturas como trabajo en curso.	Profesor	Sáb 14

Riesgo	Probabilidad	Impacto	Cómo lo manejamos	Responsable	Cuándo
Resultados inflados porque nosotros diseñamos los ataques y las defensas	🔴 Alta	🟡 Medio	Tu amigo escribe un grupo de ataques reservado antes de ver las defensas. Reportar también los falsos positivos.	Amigo	Jue 12
Mostrar en público fallas reales de SAPHEN	🟡 Media	🔴 Alto	Corregirlas antes del evento, trabajar sobre una copia local y describirlas en general.	Tú	Antes del 14
Incumplir reglas: datos personales o sistemas reales	🟢 Baja	🔴 Muy alto	Solo datos sintéticos (nombres inventados, NIT ficticio) y copia local. Revisar la lista de reglas antes de entregar.	Amigo	Sáb 14
No quedar entre los 5 finalistas por un pitch débil	🟡 Media	🔴 Alto	Ensayo cronometrado de 4 minutos. Abrir con la factura que el ataque logra aprobar.	Tú	Vie 13

El color acompaña a la palabra y nunca va solo.

4. Qué construimos el sábado (opción C)

Hora	Qué	Quién	Meta comprobable	Si falla
9:00 a 11:00	Réplica del agente del DANE: solo consultas aprobadas sobre la tabla oficial	Profesor	Responde bien 10 preguntas legítimas	Usar respuestas guardadas
9:00 a 11:00	20 a 30 ataques escondidos en documentos y el script que mide	Tú	Ataques y script listos	Bajar a 15 ataques
9:00 a 11:00	Grupo de ataques reservado y borrador de la ficha	Amigo	10 ataques que nadie más ha visto	—
11:00 a 1:00	Medición sin defensa	Tú y profesor	Tasa de éxito del ataque medida	Es el punto de control: algo debe funcionar
1:30 a 3:00	Verificador de cifras y compuerta, en modo aviso y en modo bloqueo	Profesor	Gráfico de 3 barras: sin defensa, aviso y bloqueo	Dejar solo el modo bloqueo
1:30 a 3:00	10 a 20 facturas sintéticas con instrucciones ocultas	Tú	Facturas generadas	Bajar a 5 facturas
3:00 corte	Facturas: extracción, reglas de IVA y NIT, compuerta y medición	Profesor	Tasa de éxito con y sin reglas	Se reporta como trabajo en curso
3:30 a 4:30	Ficha técnica, límites, riesgo de mal uso y video	Tú y amigo	Ficha completa	Sin video (es opcional)
4:30 a 5:00	Revisión y entrega	Todos	Enviado antes de las 5:00 p.m.	—

5. Próximos pasos

Esta semana

- **Dom 8:** confirmar al profesor y decidir la opción C.
- **Lun 9:** escribir el texto común y enviar las tres postulaciones.
- **Mié 11:** preguntar si se puede llevar código hecho; pedir la plantilla de la ficha; conseguir las claves de API.
- **Jue 12:** correr el demo de AgentBreak y probar la extracción de 2 facturas sintéticas.
- **Vie 13:** ensayar el pitch y revisar lo que hay que llevar.

Lo que debes tener claro tú

- **La idea:** los agentes que leen documentos pueden ser engañados. Ponemos controles fuera del modelo y medimos cuánto ayudan.
- **Las 3 defensas:** el documento es dato y no instrucción; consultas aprobadas con esquema estricto; verificador con compuerta.
- **La medición:** tasa de éxito del ataque sin defensa, con aviso y con bloqueo, más los falsos positivos.
- **Tu rol:** datos, métricas, ficha y pitch.